

赫卫东

30岁 | 本科 | 7年经验 | 156 4657 2521 | weidong624.he@gmail.com | 河北大学
个人简历网站 l-newbie.github.io/resume

求职意向

数据开发工程师 北京 薪资面议 在职找工作 · 到岗时间另议

个人优势

- AI 与大模型应用 —— 把大模型接进真实工程流程，而不是停在调 API —— 语义级数据精提、知识沉淀为 Agent Skill、AI 协作开发全链路；涉及AI 协作开发、开源大模型应用、Agent Skill 开发、提示工程、RAG 检索增强。
- 视觉模型与生成式 —— 不写模型结构，但清楚每类模型在什么数据上会失效、该被派去做什么 —— 检测、开放词汇检测、多模态理解、文生图与图生图，各有各的位置；涉及开放词汇检测、多模态理解、生成式数据合成、目标检测、模型评测与归因、PyTorch / OpenCV。
- 数据挖掘与闭环 —— 稀疏目标的关键不是标得更多，而是筛得更准；数据闭环的价值不在某个脚本，而在整条链路不需要人推着走；涉及长尾数据挖掘、数据闭环搭建、时序数据挖掘、爬虫与数据采集、Badcase 自动仿真、异构数据治理。
- 代码与工程交付 —— 一个人四万行代码做到上线并迭代至 v3.0。质量不靠人盯，靠 19 个功能域的自动化回归网接进提交钩子；涉及Python、自动化测试、容器化与集群部署、SQL / MySQL、Pandas / NumPy、Linux / Git。

工作

2026.03-至今 **独立开发 · 基攻宝** **AI 应用开发**

以 AI 协作为核心工作方式，独立完成从产品设计到运维的完整交付链路，验证「一人全栈」在真实复杂度下的可行性边界。

- 独立交付「基攻宝」基金实时估值系统 —— 约 4 万行 TypeScript，无后端架构，已上线并迭代至 v3.0，源码与在线体验公开
- 建立 19 个功能域的自动化回归网并接入 pre-commit 钩子，在无同行评审的条件下构造出可信的质量兜底，这也是敢于持续重构的前提
- 攻克金融计算的耦合难题：T+N 申赎确认、跨日结算、分红再投、净值重校准存在计算顺序依赖，以显式状态机替代隐式条件分支实现
- 将方法沉淀为可复用的 Agent Skill，把「AI 怎么用」从个人经验转为他人可直接调用的工程资产

2021.11-至今 **北京地平线机器人技术研发有限公司** **数据开发工程师**

主导自动驾驶动态感知的数据基础设施建设，将挖掘、标注、真值、打包四个割裂环节重构为自运转流水线，使数据供给从人力排期解耦为按需配置。

- 场景标签体系 —— 参与设计动静态障碍物场景库标签树，将「何种路况构成同一类场景」标准化为可执行规范；开发并维护自动 tagger，统筹保障标签跨专题、跨批次的一致性
- 时序数据挖掘 —— 解析仿真结果的结构化 msg，构建时序模块与 filter 模型，将离散帧级消息聚合为具明确起止边界的 timeline 事件，使动态行为成为可检索的一等对象
- Badcase 自动仿真 —— 为误检漏检制定可复现的检测规则并开发自动仿真模块，产出 web 分析大屏，将归因周期从人工排查压缩为一次看板浏览

- d. 长尾专题攻坚 —— 主导小动物检测专题，设计三级漏斗（规则粗筛 → 大模型语义精提 → 规则化人审），以递进式成本分配替代全量标注，方法论此后被复用于其他专题
- e. 全链路打通 —— 四个环节接入同一流水线，新专题接入由重写代码降级为修改配置
- f. 大模型进链路 —— 锥桶专题以 DAG 编排数据链路，接入 Qwen-VL、SAM3、YOLOv8 等开源模型做匹配与验证，配合车端结果反向验证与人工过滤，稳定支撑每个计划周期 10w+ 的数据需求

2019.06-2021.09

北京集侦云科技有限责任公司

数据分析师

面向刑侦实战的数据治理与关系建模，在数十张异构账表中还原跨境电诈的资金拆分路径，输出可直接落地侦查的结论。

- a. 异构数据治理 —— 对数十张来源各异的表执行系统性清洗与实体对齐：缺失值与异常值识别修正、重复消解、字段口径统一，使原本无法联合查询的数据具备统一检索能力
- b. 关系分级加权建模 —— 拒绝等权处理所有关联，以交易金额、频次、关系传递层级三个维度对边施加分级权重，使主干资金链自然凸显而非被低价值关联淹没，这一步直接决定分析结果的可读性
- c. 公开数据补全 —— 自研爬虫采集企业征信平台的法定代表人、股东结构与关联企业信息，将孤立的企业节点与真实自然人建立连接，拓展出仅凭内部数据无法观察的关联路径
- d. 成果落地 —— 输出带置信排序的重点账户清单交由刑侦大队逐一核实，协助勘破该案

项目

2021.03-2021.06

电诈资金流向分析

数据开发工程师

项目介绍

从数十张异构账表中还原资金拆分路径，输出可直接落地侦查的重点账户清单。一起以网络赌博为外壳的跨境电信诈骗案。资金自受害人充值入口进入后，经多层线上转账与线下取现反复拆分，最终流向境外。原始材料是数十张字段口径不一致的 Excel 与 SQL 表，账户、自然人、企业、交易流水彼此交织。此类案件的常规做法——将全部关联直接投射为关系图——只会得到一张无法解读的稠密网络：侦查需要的不是拓扑图，而是若干个可立即核查的具体账户。

工作内容

- a. 异构数据治理 —— 对数十张来源各异的表执行系统性清洗：缺失值与异常值识别修正、重复记录消解、字段口径与格式统一，完成实体对齐后整合入库，使原本无法联合查询的数据具备统一检索能力
- b. 关系分级加权建模 —— 全案的关键决策在于拒绝等权处理所有关联。以交易金额、交易频次、关系传递层级三个维度对边施加分级权重，使主干资金链在图上自然凸显，而非被数量级更大的低价值关联淹没。这一步直接决定了分析结果的可读性
- c. 公开数据补全 —— 自研爬虫系统采集企业征信平台的法定代表人、股东结构与关联企业信息，将原始数据中孤立的企业节点与真实自然人建立连接，拓展出仅凭内部数据无法观察到的关联路径
- d. 资金路径追踪 —— 沿加权后的主干链路逐层回溯拆分节点，识别通道账户与终端归集账户，形成带置信排序的重点账户清单

项目总结

数十张 异构表整合入库；3 维度关系加权模型。重点账户清单交付刑侦大队后逐一核实持有人情况，协助勘破该案。这段经历确立了我此后所有数据工作的交付标准：分析的终点是一个他人可独立核实的结论，而非一张视觉精美的关系图或一组漂亮的中间指标。该标准在后续自动驾驶评测归因中同样成立——指标退化必须能指向具体数据切片，才具备工程价值。

项目介绍

将挖掘、标注、真值、打包四个割裂环节重构为自运转流水线，把数据供给从人力排期解耦为按需配置。感知模型的迭代速度，其上界由数据供给速度决定而非算法本身。彼时的实际状况是：badcase 依赖算法工程师逐个手工收集；检索特定场景需人工遍历仿真日志；真值生产按专题各自为政、缺乏统一规范；评测指标出现退化时，无法归因至具体数据切片。链路的每一处断点都会形成工作堆积，而每一次堆积在结果上等价于模型少完成一轮迭代。问题的本质不在任何单个环节的效率，而在于整条链路缺乏自动流转能力。

工作内容

◆ 标签体系

- 参与设计动静态障碍物场景库标签树，将「何种路况构成同一类场景」这一判断标准化为可执行规范，为跨专题的数据检索建立统一语义基础
- 开发并长期维护自动 tagger，对各类标签的增量数据执行定期质检，统筹保障标签在不同专题、不同时间批次间的一致性与准确性
- 标签树落库后支撑 web 端多条件组合检索，使「找某类场景的数据」从人工遍历日志变为一次结构化查询

◆ 时序挖掘

- 基于仿真结果解析结构化 msg（时间戳、目标类型、速度、Track ID），构建时序模块与 filter 模型
- 将离散帧级消息按 Track 维度聚合为具备明确起止边界的 timeline 事件，使「某目标在某时段的完整行为」成为可检索的一等对象，而非散落的孤立帧
- 挖掘结果回写标签树数据库，与标签体系形成互补：标签负责静态场景归类，时序事件负责动态行为刻画，二者联合支撑 web 端条件检索与可视化

◆ 仿真归因

- 针对误检与漏检分别制定可复现的仿真检测规则，将「这算不算一个 badcase」从主观判断转为规则判定
- 开发自动仿真模块：任务启动后自动遍历当前专题下全部 badcase，无需人工干预
- 产出 web 端分析大屏，算法团队次日即可直接观察各类 case 的改善与退化分布，将归因周期从人工排查压缩至一次看板浏览

项目总结

4 环节接入同一流水线；配置化新专题接入方式。挖掘、标注、真值生产、数据打包四个原本割裂的环节被整合为一条可自动运转的流水线，新专题接入由重写代码降级为修改配置。这套闭环将数据供给模式从「按人力排期」转变为「按需求配置」。对我个人而言，它是我真正理解「数据基础设施」这一概念的地方——杠杆从来不在某个精巧的脚本，而在于让整条链路不再需要人推动。

项目介绍

以三级漏斗解构长尾稀疏样本挖掘，用递进式成本分配替代全量标注。自动驾驶的感知对象不止于车辆与行人。猫狗一类小动物在路面出现频率极低，但一旦发生漏检导致碾压、或误检触发幽灵刹车，其安全后果与舆论代价均极为严重。难点恰恰源自「低频」这一属性本身：在海量路采数据中，此类目标是标准的稀疏信号——全量送标成本不可接受，随机抽样又几乎无法命中正样本。这是典型的长尾数据问题，其解法不在模型侧，而在数据侧。

工作内容

◆ 三级漏斗

漏斗的设计原则是递进式成本分配：每一级都以更昂贵但更精准的手段，处理数量级更小的数据。

- a. 一级 · 规则粗筛 —— 联合内部工况标签、时间窗口，以及猫狗实际高发区域（住宅区周边、城市道路夜间时段等）先验分布进行筛选，将候选集从全量压缩至可处理量级。成本最低，负责削减数量级
- b. 二级 · 模型精提 —— 引入开源大模型执行语义级理解，从粗筛结果中提取真正可能包含目标的帧。单帧成本高于规则筛选，但作用于已缩小的候选集，总成本可控
- c. 三级 · 规则化人审 —— 制定明确的判定规则文档后由人工执行终审，产出高纯度数据集。单位成本最高，但处理量已降至最小

◆ 数据运营

- a. 标注规范治理 —— 修订标注规则文档，明确界定小动物在遮挡、模糊、远距离小目标等边界情形下的标注判据，消除标注员的主观裁量空间
- b. 质量闭环 —— 协调标注资源排期并全程监控标注质量，确保回流数据可直接使用，而非产生大规模返工
- c. 需求池建设 —— 生成标准格式训练数据与汇总文档，建立覆盖不同时间跨度与规模的数据需求池，使后续迭代可按需取数而无须从头重新挖掘
- d. 训练与发版支撑 —— 以新数据迭代模型，同步完善评测数据集与评测规则，修订发版文档，为模型上线提供完整的数据侧依据

项目总结

3 级漏斗结构；可复用 方法论已迁移至其他专题。该专题的核心产出并非某一批数据，而是一套被固化下来的长尾问题方法论：稀疏目标的关键不在于标注更多，而在于筛选更准——通过递进式成本分配，让昂贵手段只作用于高价值候选。「粗筛 → 模型精提 → 规则人审」这一结构此后在多个专题中被直接复用，成为团队处理低频类别的标准范式。

2025.08-2026.01

锥桶数据挖掘

数据开发工程师

项目介绍

以 DAG 编排整条数据链路，把多个开源大模型接进挖掘环节做匹配与验证，覆盖各场景类型的锥桶数据。锥桶是施工区域的核心语义：它标记的不是一个障碍物，而是「这条车道此刻不能走」。难点在于形态与场景的组合极多——高速养护、城区占道、事故现场、临时管制，各自的锥桶排布、密度、背景完全不同，靠单一规则或单一模型都覆盖不全。数据侧要解决的问题是：如何让一条链路同时吃下这些差异极大的场景，并且能按需扩展。

工作内容

◆ 链路编排

- a. DAG 数据链路 —— 把挖掘、匹配、验证、导出拆成可独立重跑的任务节点并以 DAG 串联，某一环失败只重跑该节点，不必从头再来
- b. 资源配置 —— 按节点的实际负载分配 CPU / GPU：规则筛选和 IO 密集的节点走 CPU，模型推理节点排 GPU，避免整条链路被最贵的那一段拖住
- c. 多下游适配 —— 同一份挖掘结果适配 2D、BEV、GOD 三个方向各自的输入格式要求，下游换方向不需要重新挖一遍

◆ 模型接入

- a. 多模型协同 —— 接入 Qwen-VL、SAM3、YOLOv8 等多个开源模型：视觉语言模型负责场景语义判断，分割与检测模型负责定位与计数，各取所长而不是指望一个模型全包
- b. 提示词工程与参数固化 —— 对提示词和模型参数逐项做对照测试，把稳定复现的组合沉淀成 config，使挖掘结果可复现、可交接，而不是依赖调参时的手感
- c. 反向验证 —— 用车端模型的输出反过来校验挖掘结果，再叠一层人工过滤，两道关卡卡住误召

项目总结

10w+ 每个计划周期的任务量；3 个下游方向共用一条链路。链路跑通之后，每个计划周期基本都能满足 10w+ 的任务需求。更关键的是扩展方式变了：新增一类锥桶场景不再是写一套新脚本，而是加一个任务节点、补一段 config —— 前面几个专题沉淀下来的「配置化接入」在这里又验证了一次。

项目介绍

把散落在文档与个人经验里的数据生产知识沉淀为 Agent Skill，封装成容器化问答服务常驻集群，团队在协作工具里直接提问即可执行答案。数据生产链路的知识高度依赖个人经验：流水线有哪些步骤、每步参数怎么填、不同项目类型的阈值差异、历史数据集与标注记录的对应关系——这些分散在文档、脚本注释和少数几个人的记忆里。新人上手要反复打断他人，老人则被同类问题反复消耗。文档本身不解决问题：它是静态的，读者仍需自行判断「我的场景该用哪组参数」。真正的瓶颈不是缺少文档，而是知识无法被随时、准确地检索到。

工作内容

◆ 知识沉淀

- 结构化重组——将全流程知识整理为一套 Agent Skill：能力概览、快速路由表、速查卡、参考文档四层结构。路由表把「用户意图」直接映射到「查哪一节」，让检索一步到位而不是全文扫读
- 边界显式声明——为 Skill 明确定义三类越界情形（数据查询超范围、功能超工具能力、流程超现有框架）及各自的处置话术。核心原则写进文档：宁可直接说「不在范围内」，也不编造任何具体 ID、路径、阈值或命令
- 可执行优先——每个能力条目都落到可直接复制运行的命令与参数，而非概念描述。判断依据（如不同项目类型的去重阈值、批大小、格式支持矩阵）以表格固化，消除口头传递中的歧义

◆ 服务化

- 协作工具接入——以事件订阅方式监听群消息，收到提问先回执确认、再异步生成答案，避免长耗时推理阻塞交互体验
- 上下文延续——以会话 ID 维持多轮对话状态，追问不必重述前提；同时约束子会话仅依据 Skill 文档作答、禁用文件搜索类工具，从机制上杜绝答案漂移到文档之外
- 结构化渲染——将 Markdown 回复解析后映射为协作平台的原生卡片元素（标题、列表、代码块、引用、表格），命令可直接复制，而不是一段难以辨读的纯文本
- 凭据安全——认证密钥以 AESGCM 加密存储于本地，运行时解出换取访问令牌，不落明文

◆ 部署运维

- 容器化交付——将运行环境固化为镜像发布到内部仓库，环境与代码一同版本化，消除「本地能跑集群跑不了」的差异
- 集群常驻——以单节点 DAG 提交至计算平台长期运行，纯 CPU 资源、不限时长；相较个人机器部署，可用性不依赖任何一台终端是否开机
- 最小权限——所有数据挂载统一降级为只读。服务只需读取知识文档，写权限对它没有意义，却会放大误操作的后果
- 进程自愈——启动时清理残留进程并写入 PID 文件，接收终止信号时回收子进程与锁文件，避免重复实例与僵尸进程

项目总结

7×24 集群常驻可用；0 答案越界编造（边界显式约束）。知识从「问人」变为「问服务」：团队在日常协作工具里直接提问即可得到带命令与参数的可执行答案，无需打断他人、也无需自行翻阅文档判断适用场景。这个项目对我的意义在于验证了一条路径——个人经验可以被系统性地转化为团队随时可调用的工程资产，而承载它的既不是一份没人读的文档，也不是一个需要专人维护的平台，而是一个能自己跑下去的服务。

项目介绍

独立完成产品设计至运维全链路的金融计算系统，约 4 万行 TypeScript，无后端架构，已开源。场内基金的实时估值分散于天天基金、东方财富、腾讯财经、Yahoo 等多个公开接口之后，数据格式各异、限流策略不一、可用性不稳定。持仓侧的复杂度更高：T+N 申赎确认、跨日结算、分红再投、净值重校准、成本基准回算——每条规则孤立看均不困难，但相互耦合后极易产生计算偏差，而偏差的对象是用户的真实资产。既有工具或要求用户将持仓数据托管至其服务器，或计算过程完全不透明、无法独立验证。

工作内容

◆ 架构

- 多 Worker 并发取数架构（v3.0 重构）—— 四个数据源互为兜底，单源失效自动降级切换，请求参数按源差异化收紧以规避限流；上一交易日数据逐条校验后方可进入缓存，杜绝脏数据污染下游计算
- 无后端设计 —— 以 JSONP 直连公开接口规避跨域限制，全部数据驻留 localStorage。该架构同时解决三个问题：零服务器成本、用户资产数据不出本地、可直接静态部署至 GitHub Pages
- PWA 完整支持 —— iOS 可添加至主屏并以独立应用形态运行；以 pageshow 事件兜底解决 Safari 页面缓存导致的跨日状态不刷新；离线状态下缓存数据仍可读

◆ 金融计算

- 完整持仓状态机 —— T+2 待确认订单在净值更新后即刻成交；同日买入与卖出互不干扰、独立结算；手工录入型持仓不被净值重校准覆盖。每一条边界条件均源自实际踩坑后的回补，而非事前设想
- 收益归因链路 —— 分红再投、成本基准回算、跨日结算三者存在计算顺序依赖，任一环节顺序错置都将导致持仓成本失真，故以显式状态机而非隐式条件分支实现
- 计算过程可审计 —— 估值推导路径对用户完全透明，这是本项目相对既有闭源工具的根本差异

◆ 质量工程

- 19 个功能域自动化回归网 —— 覆盖页面渲染、持仓计算、跨日结算、取数容错、UI 手势交互；退出码接入 pre-commit 钩子，回归失败则提交被阻断
- 可定位的失败输出 —— 失败信息精确至「卡在第几步 · 观测到的现象 · 用例所在文件」，单次改动波及的全部用例一次性呈现，消除靠猜测定位问题的环节
- 一人开发下的质量替代方案 —— 无同行评审的条件下，自动化回归网是唯一可信的质量兜底；这也是该项目敢于持续重构至 v3.0 的前提

项目总结

4 万行 TypeScript 独立交付；19 功能域回归覆盖；v3.0 已上线并持续迭代。产品设计、架构、编码、部署、运维全链路由一人完成，已上线稳定运行并迭代至 v3.0，源码与在线体验均已开放。该项目验证了一个此前未被证实的命题：在 AI 协作条件下，一名数据工程师可独立交付具备真实用户、金融计算复杂度与可控工程质量的完整产品——三者同时成立，而非以牺牲其中之一为代价。